

# Parcours d'intégration — concepts, outils et implémentations

**Institution** · Université du Québec à Trois-Rivières — Laboratoire d'innovation et de recherche en énergie intelligente (LIREI)

**Partenaire** · Ecosystem


**Programme** · Mitacs Accélération — Objectif 1, sous-objectifs 1.2 et 1.3

**Auteur** · Nilson Henao — nilson.henao@uqtr.ca

**Ce document sert à former la personne qui prend le relais du projet.** Le sous-objectif 1.1 — la fondation sémantique et le graphe — a été livré par un autre membre de l'équipe ; la personne entrante reprend les sous-objectifs **1.2** (intégration des données externes) et **1.3** (qualité, nettoyage, normalisation). Le parcours la conduit, en treize semaines à raison de 8 à 10 heures hebdomadaires, d'un profil doctoral en données et apprentissage machine jusqu'à une contribution effective. Il se suit sur des ressources publiques et des données ouvertes : aucun accès au dépôt ni aux données du partenaire avant la dernière semaine.

## 1. Contexte et architecture de référence

Les contrats à performance garantie reposent sur des prévisions d'économies que les modèles peinent à fiabiliser : l'écart entre économies prédites et mesurées — le *performance gap* — transforme une incertitude technique en passif financier. La littérature l'attribue à trois verrous : fragmentation des données du bâtiment (systèmes de gestion, BIM, audits, facturation), opacité des modèles prédictifs, biais d'optimisme des simulations. Le projet y répond sur trois ans : un **graphe de connaissances** qui unifie les données et sert de mémoire des projets passés (année 1) ; un **regroupement** dérivant des classes de référence objectives (année 2) ; des **modèles interprétables** produisant des prévisions explicables et dé-biaisées (année 3). La contribution attendue porte sur la première année.



Architecture de référence en six couches : définition, ingestion, stockage, intelligence, évolution, interrogation.

L'architecture de référence organise ce travail en six couches. Les produits nommés dans les boîtes sont indicatifs : chaque couche désigne un **rôle**, et l'implémentation peut différer — la carte des outils (§4) donne les alternatives.

| Couche            | Rôle                                                            | Semaines              |
|-------------------|-----------------------------------------------------------------|-----------------------|
| 1 · Définition    | Vocabulaire versionné, chargeur, registre                       | S4                    |
| 2 · Ingestion     | Charger, extraire, valider, <b>résoudre l'identité</b> , écrire | S1–S2, S5–S9, S12     |
| 3 · Stockage      | Graphe et provenance                                            | S3, S6                |
| 4 · Intelligence  | Raisonnement, plongements, questions de compétence              | S3 (questions seules) |
| 5 · Évolution     | Diff sémantique et approbation humaine                          | S8, S12               |
| 6 · Interrogation | Surfaces de requête standard                                    | S3                    |

Deux manques structurent le parcours : la **résolution d'identité** en couche 2 et le **raisonnement** en couche 4, dont l'absence oblige à matérialiser ce qu'une requête doit voir. Les plongements relèvent des objectifs 2 et 3.

## 2. Intention

La documentation de la plateforme suppose ces couches et leurs technologies acquises. Le parcours ordonne donc les **concepts** avant les outils, situe chaque outil dans sa famille, et enchaîne des implémentations réelles : chaque semaine prolonge le dépôt personnel de la précédente.

À l'issue, la personne sait modéliser un domaine en RDF, l'interroger et le valider ; construire une chaîne source — graphe reproductible séparant construction, validation et publication ; profiler des séries de compteurs et marquer les anomalies sans les effacer ; rapprocher des entités sous revue humaine ; distinguer une économie estimée, observée ou vérifiée. Hors visée : administrer un orchestrateur en production ou écrire des ontologies OWL complètes.

Chaque semaine donne une question directrice, les notions introduites, les lectures, une implémentation versionnée et un critère de sortie. Une semaine peut en prendre deux : le parcours se décale sans se raccourcir.

Cinq réflexes fondés en science des données changent de sens ici. **L'absence reste explicite** : toute imputation est tardive et marquée. **La réussite d'un outil n'admet rien** : l'admission repose sur des règles explicites. **Un résultat sans identité n'est pas reproductible**. **L'égalité de nom est un indice, pas une preuve** : fusionner en silence invente une équivalence. **Estimé, observé et vérifié sont trois natures**, aux exigences de preuve différentes. Le principe qui les unit : **l'abstention est une réponse valide** — un refus motivé, jamais une valeur approchée.

## 3. Position dans le projet

L'objectif 1 construit le graphe et y aligne les données ; les objectifs 2 et 3 l'exploitent et restent hors périmètre. Le sous-objectif 1.1 — fondation sémantique — est livré : le premier mois sert à savoir le lire, non à le refaire. La contribution porte sur 1.2 et 1.3, que trois questions ouvertes délimitent.

- **Résolution d'identité** — une même entité arrive de sources différentes sous des identifiants issus de schémas distincts. Décider qu'ils désignent la même chose exige un critère explicite, une confirmation humaine enregistrée, et le refus de publier une correspondance non revue.

- **Réconciliation de vocabulaire** — sans définitions ni relations associatives, l'appariement d'un texte libre au vocabulaire est impossible ; passer d'une taxonomie à un thésaurus conditionne l'ingestion documentaire.
- **Acquisition de preuve** — certaines données n'existent pas dans un état attribuable et autorisé ; les obtenir relève de la coordination externe. Reconnaître ce cas et le documenter est une contribution.

## 4. Carte des outils

| Rôle                          | Outil                            | Alternatives                   | Pourquoi ici                                                                      |
|-------------------------------|----------------------------------|--------------------------------|-----------------------------------------------------------------------------------|
| RDF en Python                 | <b>rdflib</b>                    | Jena, rdf4j ; pyoxigraph       | La chaîne du projet est en Python.                                                |
| Stocker, interroger           | <b>Oxigraph</b>                  | Fuseki, GraphDB, Virtuoso      | Graphes nommés, <b>sans raisonnement</b> : l'interrogeable doit être matérialisé. |
| Valider                       | <b>pySHACL</b>                   | TopBraid, Jena SHACL, ShEx     | Porte d'admission, pas rapport.                                                   |
| Transformer en RDF            | <b>morph-kgc + YARRRML</b>       | RMLMapper, SDM-RDFizer         | S'audite ; artefact le plus souvent modifié.                                      |
| Orchestrer                    | <b>Dagster</b>                   | Airflow, Prefect, Kedro        | Déclarer les résultats rend visible ce qu'un échec bloque.                        |
| Provenance                    | <b>PROV-O</b>                    | Dublin Core seul               | Donnée du graphe, interrogeable.                                                  |
| Vocabulaires, correspondances | <b>QUDT, SOSA, Brick ; SSSOM</b> | Haystack, 223P ; sameAs nu     | Réutiliser plutôt qu'inventer ; une correspondance porte justification et auteur. |
| Rapprocher                    | <b>splink</b>                    | Record Linkage Toolkit, dedupe | Score par paire ; le seuil reste humain.                                          |
| Modèles de référence          | <b>eemeter</b>                   | IMT ASHRAE, RMV2.0 (R)         | CalTRACK, hypothèses explicites.                                                  |
| Anomalies                     | <b>scikit-learn</b>              | PyOD                           | L'enjeu : gouvernance, angles morts saisonniers.                                  |

## 5. Environnement

Python 3.12 avec `rdflib`, `pyshacl`, `pyoxigraph`, `morph-kgc`, `pandas`, `scikit-learn`, `splink`, `eemeter` ; Protégé ; Docker dès la semaine 3. Un dépôt Git personnel reçoit chaque semaine un répertoire, un README et des tests. Jeu de données : le [Building Data Genome Project 2](#) — 3 053 compteurs horaires, 1 636 bâtiments, métadonnées et météo ([Miller et al., 2020](#)) ; vingt suffisent. Degrés-jours : [ECCC](#).

## 6. Mois 1 — Représentation et interrogation (≈ 36 h)

Fond du mois, suivi en parallèle semaine par semaine : le [MOOC Inria « Web sémantique et Web de données »](#) (FR, gratuit).

**S1 · Modèle et justification du graphe.** *Qu'apporte un graphe gouverné face à un schéma relationnel, et à quel coût ?* Relations nommées, IRI globaux, vocabulaire versionné à part ; monde ouvert — une valeur manquante n'est pas un zéro ; intégrer sans fusionner. **Lire** — Hogan et al., [Knowledge Graphs](#) ch. 1–3 (4

h) ; [graphes de données](#) (INRAE, FR). **Faire** — depuis `metadata.csv` de BDG2, un graphe de dix bâtiments, sites et stations, IRI dérivés des identifiants source. **Sortie** — le graphe et une note d'une page comparant au schéma relationnel : ce qui devient trivial, ce qui devient coûteux.

**S2 · Sérialisations, types, graphes nommés.** *À quoi servent les graphes nommés, et pourquoi N-Triples pour archiver ?* Littéraux typés — "12" n'est pas 12. Les graphes nommés partitionnent par source, version ou autorité, ce qui permet de publier des lots. N-Triples est canonique, donc hachable. **Lire** — [RDF 1.1 Primer](#) et [Concepts](#) (2 h). **Faire** — un mois de relevés horaires pour trois compteurs, typés, répartis avec bâtiments et météo dans trois graphes nommés ; export N-Triples trié et empreinte SHA-256. **Sortie** — deux exports, même empreinte.

**S3 · SPARQL.** *Comment écrire une requête dont le résultat vide distingue « aucun fait » de « fait inconnu » ?* OPTIONAL, NOT EXISTS, MINUS ; les pièges de comptage de OPTIONAL + FILTER ; GRAPH, agrégats. La question de compétence : question métier en SPARQL, résultat attendu fixé, exécutée comme test. **Lire** — [tutoriel SPARQL Wikidata](#) (FR, 3 h) ; [SPARQL 1.1](#) en référence. **Faire** — charger le Dataset dans Oxigraph ; quinze questions de compétence avec leur résultat attendu, dans une suite `pytest`. **Sortie** — suite verte, dont trois questions distinguent absence et zéro.

**S4 · Vocabulaires et ontologies.** *Comment réutiliser les vocabulaires du domaine sans les redéfinir ?* OWL 2 — `inverseOf`, modularité par `owl:imports` et `versionIRI` ; SKOS ; séparation TBox / ABox. Sans raisonnement, un inverse déclaré n'est pas déduit : ce qu'une requête doit voir doit être matérialisé. **Lire** — Noy & McGuinness, [Ontology Development 101](#) (1 h 30) ; [Brick](#) (1 h) ; [SOSA](#), [QUDT](#), [SKOS](#) en survol. **Faire** — réécrire le graphe sur les vocabulaires standards et un module `mon-domaine.ttl` qui les importe en ne déclarant que les termes locaux. **Sortie** — les quinze questions de compétence passent encore.

**Bilan** — une heure : dépôt, exécution de la suite, discussion de la note comparative de S1.

## 7. Mois 2 — Chaîne gouvernée et qualité (≈ 45 h)

**S5 · Validation par formes.** *Comment exprimer les conditions d'admission d'une donnée sous forme lisible et versionnée ?* Formes de nœud et de propriété, cardinalités, contraintes SPARQL, sévérités. C'est une **porte d'admission** : un candidat non conforme n'est pas publié, son rapport est conservé comme preuve. Elle ne déduit rien. **Lire** — Labra Gayo et al., [Validating RDF Data](#), chapitres SHACL (3 h) ; [SHACL Playground](#) pour itérer. **Faire** — des formes exigeant qu'un relevé porte une valeur numérique, une unité d'un ensemble fermé, un intervalle et une provenance ; pySHACL dans `pytest`, fixtures valides et invalides. **Sortie** — le graphe du mois 1 est admis, chaque fixture invalide produit le rapport attendu.

**S6 · Provenance, empreintes, lots immuables.** *Comment garantir qu'un graphe publié se reconstruit à l'identique ?* PROV-O : entité, activité, agent. Un manifeste lie les empreintes des entrées, des règles et des sorties. Un lot ne se modifie pas ; un nouveau le remplace atomiquement ; un retour arrière resélectionne un lot antérieur sans le reconstruire. **Lire** — [PROV Primer](#) (1 h). **Faire** — provenance de chaque relevé (source et empreinte, activité, SHA Git) ; `build.py` produisant un répertoire immuable nommé par l'empreinte de son manifeste. **Sortie** — idempotence démontrée et sensibilité à toute modification d'entrée, ancien lot intact.

**S7 · Mappings déclaratifs.** *Comment remplacer un script de transformation par une spécification auditable, et où s'arrête sa responsabilité ?* Sources logiques, cartes de sujets, de prédicats et d'objets, jointures ; YARRRML comme syntaxe YAML. Le mapping traduit : ni logique métier ni décision de qualité. **Lire** — [YARRRML](#) et [Matey](#) (2 h) ; [morph-kgc](#) (1 h). **Faire** — remplacer le code des semaines 1 à 4 par des règles YARRRML sur les CSV BDG2, et brancher `morph-kgc` dans `build.py` de sorte que les règles entrent dans le manifeste. **Sortie** — construction déclarative, formes et questions toujours vertes.

**S8 · Orchestration par actifs.** *Comment garantir qu'un échec ne publie rien, et séparer construction, approbation et publication ?* On déclare les résultats et leurs dépendances, l'orchestrateur en dérive l'ordre — là où un DAG décrit des exécutions. Il construit un candidat lié par empreinte ; approbation et publication sont des actes distincts. **Lire** — [Dagster Essentials](#) (5 h) ou le [tutoriel officiel](#) (2 h). **Faire** — réécrire `build.py` en graphe d'actifs (source → normalisation → candidat RDF → manifeste → validation), deux vérifications — identité des entrées, conformité SHACL — et un actif `publier` séparé, manuel. **Sortie** — un échec de conformité laisse le répertoire courant strictement inchangé.

**S9 · Qualité des séries de compteurs.** *Comment marquer les anomalies sans les effacer ?* Complétude, validité, cohérence, actualité ; profilage avant toute action. Défauts typiques : lacunes, plateaux, remises à zéro, changements d'unité, heure avancée. Une anomalie est **marquée** avec méthode et seuil, jamais supprimée ; les détecteurs génériques ont des angles morts saisonniers. **Lire** — notebooks du dépôt BDG2 (2 h) ; [IsolationForest](#) ; [qualité des données](#) (GBIF, FR, 1 h). **Faire** — pour vingt compteurs : profil de qualité, détection par Z-score saisonnier et Isolation Forest ; annotation typée des relevés douteux et forme SHACL exigeant que toute annotation porte sa méthode. **Sortie** — trois états distingués par requête — valide, marqué douteux avec méthode, absent — sans aucune suppression.

**Bilan** — une heure : graphe d'actifs de bout en bout, échec bloquant démontré, rapport de qualité. Savoir dire, pour chaque étape, quelle autorité elle détient.

## 8. Mois 3 — Domaine, identité, méthode (≈ 36 h)

**S10 · Comparabilité et normalisation.** *À quelles conditions deux consommations sont-elles comparables ?* Intensité d'utilisation énergétique et ses pièges — surface de référence, périmètre des usages. Pour les degrés-jours, la station, la période, la méthode et la température de base font partie de la donnée. Normalisation *fail-closed* : unité inconnue ou station manquante → abstention motivée. **Lire** — [Climate and Weather](#) (ENERGY STAR, 45 min) ; [degrés-jours](#) (ECCC, FR). **Faire** — un module de comparabilité : conversion vers kWh et m<sup>2</sup> depuis un ensemble fermé d'unités QUDT, normalisation par degrés-jours avec station, période et base explicites, abstention typée ; tests par motif. **Sortie** — les abstentions sont aussi visibles que les résultats, inscrites dans le graphe avec leur règle.

**S11 · Modèles de référence et IPMVP.** *Qu'est-ce qui distingue une estimation, une observation et une économie vérifiée ?* Régression à points de rupture sur la température ; CV(RMSE) et NMBE ; critères d'admissibilité. IPMVP : options A à D, périodes de référence et de suivi, ajustements. *eemeter* est un bon objet d'étude : ses hypothèses sont explicites. **Lire** — [IPMVP](#) (FR, 3 h ; édition courante chez [EVO](#)) ; [eemeter](#) et son [tutoriel](#) (2 h) ; Kissock et al., [Inverse Modeling Toolkit](#) (1 h). **Faire** — pour cinq bâtiments : modèle journalier sur une année, CV(RMSE) et NMBE, identification des modèles non admissibles ; période de suivi simulée et usage évité. **Sortie** — une note classant chaque résultat comme *estimé*, *observé* ou *vérifié*, et listant ce qui manque pour monter d'une catégorie.

**S12 · Résolution d'identité et alignement.** *Comment décider que deux identifiants désignent la même entité, de façon révisable et attribuable ?* Blocage, comparaison, modèle de Fellegi-Sunter, seuils, et le cas délibérément *non résolu*. Une correspondance porte critère, confiance et auteur ; elle ne s'applique jamais en silence. Pour l'alignement, préférer la relation la plus faible qui suffit — subsomption plutôt qu'équivalence. C'est le problème qui vous attend : une même station sous deux identifiants issus de schémas distincts. **Lire** — [slink](#), tutoriel et exemples (3 h) ; [SSSOM](#) et la section identité de *Knowledge Graphs* (1 h 30). **Faire** — rapprocher les stations météo de BDG2 avec celles d'ECCC (blocage géographique, noms et coordonnées, `slink`, seuils) en produisant une table à statuts *confirmée* / *à revoir* / *non résolue*, dont seules les confirmées entrent dans le graphe ; puis publier en SSSOM l'alignement vers Brick, SOSA et QUDT. **Sortie** — au moins un cas non résolu argumenté.

**S13 · Design Science Research et cadrage.** *En quoi le travail à venir relève-t-il de la recherche ?* Artefact, pertinence, rigueur, cycles de conception et d'évaluation ; l'évaluation est un résultat, et un résultat

négligé se conserve. **Lire** — Hevner et al., [Design Science in IS Research](#) (2 h) ; les références de la proposition, remises par l'encadrement. **Faire** — un plan de travail de quatre pages pour une première contribution à 1.2 ou 1.3, structuré selon DSR : problème, artefact visé, critères d'évaluation, sources et leur autorité, risques. **Sortie** — le plan et un exposé de trente minutes : le dépôt de bout en bout et les décisions de conception.

**Bilan final** — exposé devant l'équipe et discussion. L'accès au dépôt s'ouvre ensuite.

## 9. Sur place, et premiers jours

Aucune préparation n'est requise sur la façade de commandes, Docker Compose, le registre d'ontologies, l'intégration continue et l'observabilité : il suffit de savoir que la CI rejoue les tests sans secret — un test qui contacte le réseau y échoue — et que l'observabilité produit des signaux dérivés, jamais une source de vérité. Premiers jours : test de fumée local ; documentation — concepts, puis architecture ; carte des capacités, qui indique jusqu'où chaque fonction est prouvée ; rencontre avec l'auteur du sous-objectif 1.1 pour faire corriger sa compréhension de la fondation ; une première contribution bornée ; puis cadrage écrit de la première tâche réelle.

## 10. Références

**Fondements et standards.** Hogan et al., [Knowledge Graphs](#) (gratuit) · [MOOC Web sémantique et Web de données](#) (Inria / FUN, FR) · [CS520](#) (Stanford) · [Introduction aux graphes de données](#) (INRAE, FR) · [W3C : RDF Primer](#), [RDF Concepts](#), [SPARQL 1.1](#), [SHACL](#), [PROV Primer](#), [PROV-O](#), [SKOS Primer](#), [SOSA/SSN](#) · Noy & McGuinness, [Ontology Development 101](#) · [Brick](#), [QUDT](#), [RealEstateCore](#), [SSSOM](#) · [Tutoriel SPARQL Wikidata](#) (FR).

**Validation, construction, qualité, identité.** Labra Gayo et al., [Validating RDF Data](#) (gratuit) · [pySHACL](#), [SHACL Playground](#) · [rdflib](#), [pyoxigraph](#), [Oxigraph](#) · [morph-kgc](#), [YARRRML](#), [RML](#) · [Dagster Essentials](#), [Dagster docs](#) · [Principes de qualité des données](#) (GBIF, FR) · [scikit-learn IsolationForest](#) · [splink](#) · Christen, [Data Matching](#), Springer 2012 (payant).

**Énergie des bâtiments et méthode.** Miller et al., [Building Data Genome Project 2](#), Scientific Data 2020 · [dépôt](#) · [ENERGY STAR — Climate and Weather](#) · [Données climatiques du Canada](#) (ECCC, FR) · [IPMVP 2010](#) (FR), [EVO](#) · [eemeter / OpenEEmeter](#) · Kissock et al., [Inverse Modeling Toolkit](#) (ASHRAE) · Hevner et al., [Design Science in IS Research](#) (MIS Quarterly 2004).

## 11. Glossaire

| Français               | Anglais             | Définition opératoire                                                            |
|------------------------|---------------------|----------------------------------------------------------------------------------|
| TBox / ABox            | TBox / ABox         | Définitions du vocabulaire / faits sur les entités ; publication séparée.        |
| Graphe nommé           | named graph         | Partition identifiée ; unité d'appartenance et de publication.                   |
| Forme                  | shape               | Condition d'admission exprimée en SHACL.                                         |
| Question de compétence | competency question | Question métier en SPARQL, résultat attendu fixé, exécutée comme test.           |
| Provenance             | provenance          | Source, transformation et agent, en PROV-O dans le graphe.                       |
| Manifeste              | manifest            | Empreintes des entrées, règles et sorties d'une construction.                    |
| Lot, génération        | generation          | Ensemble publié atomiquement, immuable, adressé par contenu.                     |
| Matérialisation        | materialization     | Construction déterministe d'un candidat, sans autorité de publication.           |
| Actif                  | asset               | Résultat déclaré d'une chaîne, avec dépendances et vérifications.                |
| Mapping déclaratif     | declarative mapping | Règles RML/YARRRML transformant une source en RDF.                               |
| Résolution d'identité  | entity resolution   | Décision, sous critère et revue, que deux identifiants désignent la même entité. |
| Alignement             | alignment           | Correspondance entre concepts de vocabulaires différents, avec métadonnées.      |
| Abstention             | abstention          | Refus motivé et stable faute de preuve suffisante.                               |
| IUÉ                    | EUI                 | Énergie annuelle par unité de surface, sous conditions de comparabilité.         |
| Degrés-jours           | degree days         | Rigueur climatique ; station, période, base et méthode en font partie.           |
| Modèle de référence    | baseline model      | Modèle de consommation avant intervention, avec critères d'admissibilité.        |
| Mesure et vérification | M&V                 | Protocole faisant passer une économie d'estimée à vérifiée.                      |